

TD5 –CAH

Exercice 1 : Insuffisance rénale

- Télécharger le jeu de données *Insuffisance Rénale L3.csv* et faites en sorte de traiter la colonne sans nom comme *index*.
- Quelle est la taille du *dataSet*, y-a-t-il des valeurs manquantes.
- Au regard des valeurs maximales de chaque colonne que peut-on en conclure, sur l'importance que pourraient avoir chacune des *feature* sur l'apprentissage.
- Récupérez toutes les données exceptée la *feature* cible.
- Affichez le *dendogram* sur les données issues de fonction *linkage* de *scipy.cluster.hierarchy*.
- Choisissez un regroupement en 3 classes et effectuer l'apprentissage avec un *AgglomerativeClustering* avec l'option *distance_threshold=None*.
- Ajoutez maintenant un colonne *cluster* et une colonne *class* correspondant aux clusters calculés avec *AgglomerativeClustering* et à la *target* du *dataset* d'origine.
- Calculez maintenant pour chaque *cluster* combien de patients ont une insuffisance rénale ou pas. Commentez les résultats obtenus.

Exercice 2 : Insuffisance rénale – données normalisées

- Effectuer une normalisation des données en utilisant un *standardScaler*.
- Comment se répartissent les données.
- Affichez le nouveau *dendogram* comment peut-on interpréter les différences avec le précédent.
- Effectuer la même *clusterisation* avec 3 clusters.
- Comment se répartissent les classes en fonction des clusters. Que constatez-vous.
- Comment peut-on interpréter les différences entre les deux *clusterisations*.

Colonnes du *dataFrame* :

- *age* ; *bp* (pression artérielle) ; *sg* (densité spécifique) ; *al* (albumine)
- *su* (sucre) ; *rbc* (cellules de globules rouges) ; *pc* (cellule de pus) ;

- *pcc (amas de cellules de pus) ; ba (bactéries) ; bgr (glycémie)*
- *bu (urée sanguine) ; sc (créatinine sérique) ; sod (sodium)*
- *pot (potassium) ; hemo (hemoglobine) ; pcv (volume d'hématocytes)*
- *wc (globules blancs) ; rc (nombre de globules rouges) ; htn (hypertension)*
- *dm (diabète) ; cad (maladie de l'artère coronaire) ; appet (appétit)*
- *pe (œdème de la pédale) ; ane (anémie) ; class (insuffisance rénale)*