

TD6 – Kmean

Exercice 1 : Analyse des données

- Télécharger le fichier *Clients.csv* et utiliser la colonne sans nom comme colonne d'index.
- Combien y-a-t-il des valeurs manquantes. Supprimez ces valeurs.
- Sur la base des colonnes [Age, Diplôme, Revenu, Client Depuis, Montant] combien y-a-t-il de doublons. Supprimez ces valeurs.
- Au regard de la fonction *describe* pensez-vous qu'il y ait des outliers. Faites bien la différence avec les valeurs extrêmes.
- Combien de personnes d'on l'âge et le revenu sont supérieures à $Q_{max} = Q_3 + 3 * (Q_3 - Q_1)$. Supprimez ces valeurs.
- Combien y-a-t-il de valeurs différentes pour chaque valeur d'Etat Civil. Affichez via *boxplot* et un *whis* à 3 la répartition des revenus sur ces valeurs. Commentez les résultats.
- Effectuez le même travail pour la colonne *Diplôme*.
- Affichez pour les colonnes *Age*, *Revenu* et *Montant* avec un *hisplot* en fonction des diplômes. Commentez les résultats.
- Affichez la corrélation entre les variables numériques.
- La colonne *Reponse* est liée aux campagnes marketing. Quelles sont les personnes les plus réactives aux campagnes marketing en fonction de l'état civile.
- Quel est la somme moyenne dépensée *Montant* en fonction des *Diplômes*.

Exercice 2 : Clustering

- On souhaite classer les clients en fonction des seules informations : [Age, Revenu, Montant, nbAchatWeb, nbAchatMag, nbAccesWebMois]. Récupérez dans un *dataFrame* uniquement ces colonnes.
- Normalisez les données grâce à *StandarScaler*.
- Effectuer plusieurs modèles *Kmeans* avec des nombres cluster de 2 à 30. Affichez comment évolue l'inertie. Quel est selon vous bon nombre de clusters.
- Utilisez un modèle *KElbowVisualizer* initialisé avec deux paramètres un *Kmeans* et les tailles des clusters $k=(2,n)$, puis entraîné sur les données normalisées, pour visualiser de manière plus exacte le nombre de clusters.

- *Utilisez maintenant le modèle Kmeans avec le bon nombre de clusters.*
- *Affichez pour les colonnes qui ont servi d'apprentissage les moyennes sur les différents clusters.*
- *Comment se répartissent les clients. Les groupes sont-ils homogènes en nombre de clients.*
- *Analysez ces résultats, comment sont regroupé les clients, sur la base de quels informations ces regroupements sont-ils réalisés.*
- *Afin de compléter votre analyse vous afficherez le montant des achats et les revenus en fonction de Cluster et des Diplôme.*
- *Effectuez une réduction de dimension via un PCA en ne conservant que les deux premiers vecteurs propres. Pensez-vous que ces deux dimensions expliquent le modèle.*
- *Affichez la répartition des revenus et des dépenses en fonction des classes. Que pouvez-vous en conclure.*
- *Affichez maintenant la répartition des classes en fonction de ces deux valeurs propres. Comment sont classés les clients.*

Informations :

- *Les fonctions **uplicated** et **drop_duplicated** permettent d'identifier et de supprimer les doublons. Le paramètre subset est utilisé pour sélectionner les colonnes sur lesquelles rechercher les doublons.*
- *La fonction **dropna** permet de supprimer les valeurs manquantes.*
- *La bibliothèque **yellowbrick.cluster** propose une fonction **KElbowVisualizer** qui permet de choisir le nombre de cluster basée sur la méthode du coude. Le modèle doit être entraîné sur plusieurs valeur k (nombre de clusters).*